LAPORAN DATA PREPROCESSING
UK ROAD SAFETY OPEN DATA 2025

1. Dataset Description & Justification

Dataset yang digunakan adalah UK Road Safety Open Data 2025 dari Department for Transport (DfT), United Kingdom. Dataset terdiri dari tiga tabel record-level, yaitu Collision, Vehicle, dan Casualty. DfT menjelaskan bahwa data ini mencakup personal-injury road collisions di Great Britain yang dilaporkan kepada polisi dan dicatat menggunakan sistem STATS19. Data DfT 2025 menyediakan tiga tabel utama, yaitu Collision, Vehicle, dan Casualty, serta Data Guide untuk memahami kode pada setiap field. [1]

Dataset dipilih karena bersifat open data, terdiri dari beberapa tabel yang harus diintegrasikan, memiliki kode khusus dan missing value yang perlu diverifikasi, memiliki atribut numerik dengan skala berbeda, serta mempunyai jumlah atribut yang cukup besar untuk menunjukkan kebutuhan attribute selection dan dimensionality reduction. Proses preprocessing mengikuti konsep data preprocessing yang mencakup data cleaning, data integration, dan data reduction. [2]

Landasan teori utama yang digunakan adalah Han, J., Kamber, M., & Pei, J., Data Mining: Concepts and Techniques, 3rd ed., Morgan Kaufmann, 2012. Buku ini membahas data preprocessing, termasuk data cleaning, data integration, data reduction, transformasi data, serta outlier detection. [3]

2. Preprocessing Method & Rationale

Tahap	Metode	Alasan / keputusan
1.Understanding & Profiling	Grain, key, dtype, missing, duplicate, special code	Menentukan bentuk data dan apa yang diwakili oleh setiap baris sebelum data diolah.
2. Data Cleaning	Validasi kode -1 berdasarkan Data Guide dan screening potential outlier menggunakan IQR.	Kode tidak diubah tanpa definisi resmi. IQR hanya digunakan untuk menandai data yang perlu diperiksa lebih lanjut.
3. Data Integration	Left merge berdasarkan key dan validasi cardinality	Menggabungkan data tanpa menghilangkan vehicle involvement serta menghubungkan casualty sesuai relasi 1:M.
4. Attribute Selection	Pearson correlation dan pemilihan berdasarkan peran variabel.	Mendeteksi variabel yang berpotensi redundan dan memilih fitur numerik yang relevan untuk PCA tanpa mengubah dataset utama.
5. Data	StandardScaler dan PCA	Menstandarkan skala fitur, kemudian

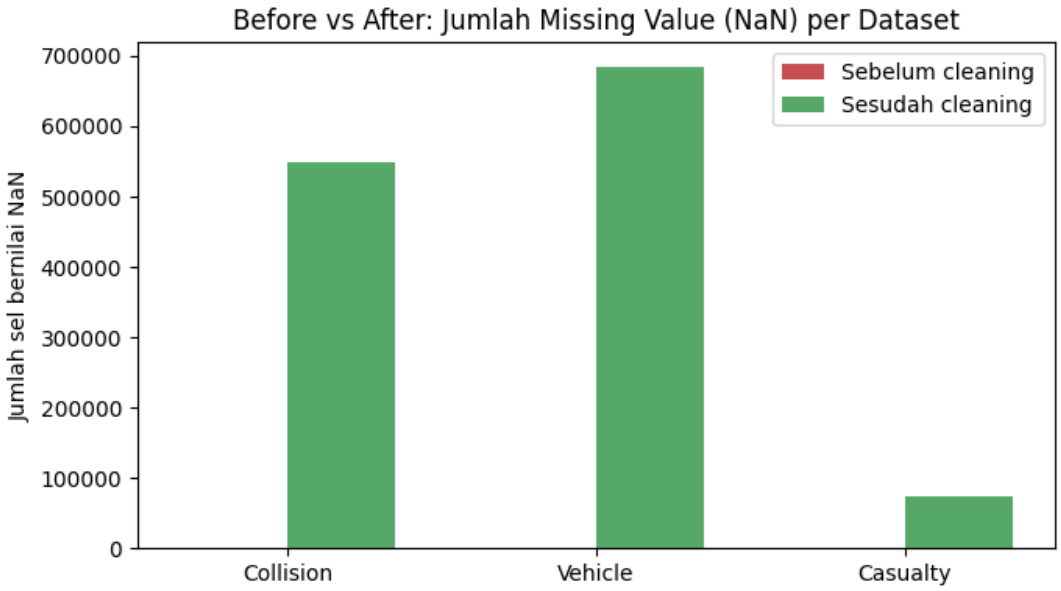
Reduction	dengan target cumulative variance 90%.	mengurangi jumlah dimensi dengan tetap mempertahankan sebagian besar variance data.
6. Visualization & Evaluation	Before-after tables, bar charts, heatmap, scree/cumulative plot, dan PCA projection.	Mengevaluasi hasil setiap tahap preprocessing tanpa melakukan perubahan data tambahan.

3. Data Understanding & Cleaning

Pada tahap profiling, unit data dibedakan berdasarkan tabel. Satu baris pada Collision mewakili satu kecelakaan, satu baris pada Vehicle mewakili satu vehicle involvement, dan satu baris pada Casualty mewakili satu korban. Pemeriksaan candidate key pada notebook menunjukkan tidak terdapat duplicate key pada masing-masing tabel. Jumlah data awal yang digunakan adalah 101.525 Collision, 183.948 Vehicle, dan 127.883 Casualty.

Cleaning tidak dilakukan dengan menghapus semua nilai ekstrem. Nilai khusus seperti -1 diverifikasi menggunakan Data Guide karena maknanya dapat berbeda pada setiap atribut. Jika Data Guide menjelaskan -1 sebagai nilai missing atau unknown, nilai tersebut diubah menjadi NaN. Sebaliknya, kode -1 yang memiliki arti lain tetap dipertahankan. Lima atribut konstan dan atribut administratif tidak langsung dihapus dari dataset utama, tetapi dipertimbangkan kembali saat memilih feature set analitis pada Stage 4.

IQR digunakan untuk screening potential outlier. Hasil boxplot menunjukkan adanya nilai ekstrem pada beberapa variabel. Namun, nilai ekstrem tidak langsung dianggap sebagai kesalahan karena nilai tersebut belum cukup untuk membuktikan adanya kesalahan pencatatan. Oleh karena itu, observasi yang melewati batas 1,5 IQR tidak otomatis dihapus. Pendekatan ini membuat proses cleaning tetap berdasar



Gambar 1. Perbandingan jumlah missing value sebelum dan sesudah cleaning pada tiga tabel. Sumber: Output notebook Stage 2.

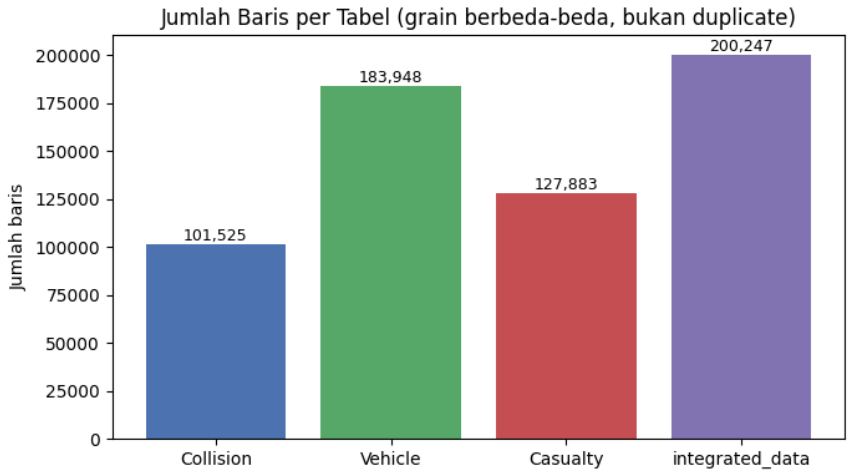
Hasil cleaning tidak mengubah jumlah baris pada setiap tabel. Perubahan dilakukan pada nilai khusus yang berdasarkan Data Guide memiliki arti missing atau unknown, sehingga nilai tersebut diubah menjadi NaN. Tidak ada penghapusan baris secara massal.

4. Data Integration

Integrasi dilakukan secara bertahap dari Collision, Vehicle, hingga Casualty. Tabel Collision dan Vehicle dihubungkan menggunakan collision_index dengan relasi 1:M. Selanjutnya, Vehicle dan Casualty dihubungkan menggunakan collision_index dan vehicle_reference, juga dengan relasi 1:M. Proses integrasi menggunakan left merge sehingga vehicle yang tidak memiliki casualty tetap dipertahankan. Dengan demikian, grain tabel hasil akhir mengikuti data yang terhubung, yaitu satu baris mewakili satu casualty yang terhubung atau satu vehicle tanpa casualty.

Data / hasil	Rows	Columns	Validasi
Collision clean	101.525	44	candidate key collision_index: 0 duplicate
Vehicle clean	183.948	32	candidate key collision_index + vehicle_reference: 0 duplicate
Casualty clean	127.883	23	candidate key collision_index + vehicle_reference + casualty_reference: 0 duplicate
Integrated data	200.247	96	0 duplicate candidate key; coverage relasi tervalidasi

Jumlah baris meningkat dari 183.948 pada tabel Vehicle menjadi 200.247 setelah digabungkan dengan Casualty. Peningkatan ini terjadi karena satu vehicle dapat memiliki lebih dari satu casualty, sedangkan vehicle yang tidak memiliki casualty tetap dipertahankan melalui left merge. Peningkatan jumlah baris tersebut tidak menunjukkan adanya duplicate, karena pemeriksaan candidate key pada notebook menunjukkan 0 duplicate key.



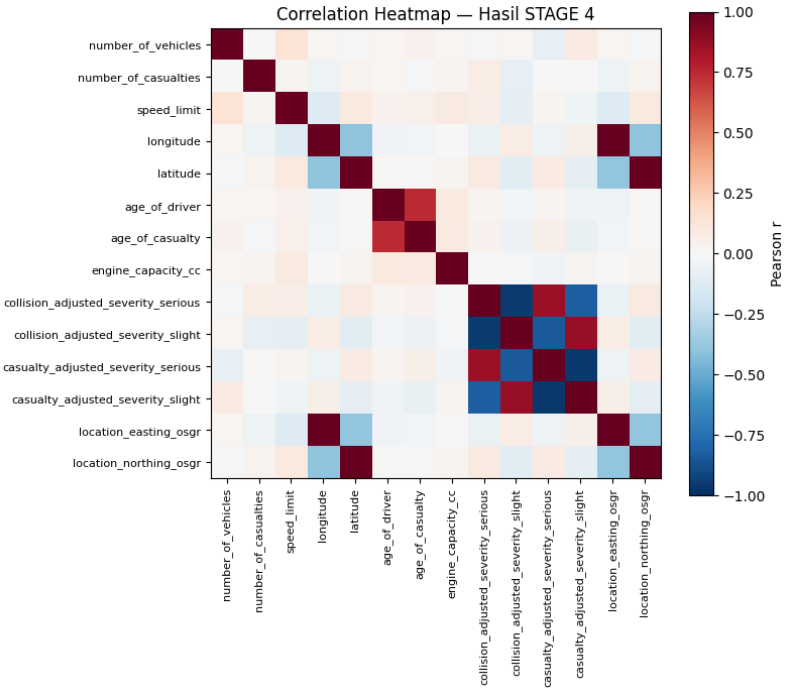
Gambar 2. Jumlah baris pada setiap tabel berdasarkan grain. Integrated data tidak dapat dibandingkan langsung dengan jumlah collision karena grain berbeda.

5. Redundancy Analysis & Attribute Selection

Dari 96 atribut pada integrated_data, notebook membentuk analytical feature set berdasarkan peran atribut dan hasil profiling. Pearson correlation digunakan untuk melihat hubungan linear antarfitur numerik. Threshold $|r| \geq 0{,}80$ digunakan untuk menemukan atribut yang berpotensi memberikan informasi yang serupa, bukan sebagai aturan otomatis untuk menghapus atribut.

Ditemukan korelasi tinggi antara longitude dan latitude dengan location_easting_osgr dan location_northing_osgr. Kedua kelompok atribut tersebut sama-sama merepresentasikan lokasi, karena koordinat geografis dipertahankan, location_easting_osgr dan location_northing_osgr tidak dimasukkan ke analytical feature set. Lima atribut konstan juga tidak dimasukkan karena tidak memiliki variasi. Selain itu, dua atribut hasil duplikasi merge tidak memberikan informasi baru sehingga tidak dimasukkan.

Empat atribut adjusted severity memiliki korelasi tinggi, dengan nilai sekitar -0,96 hingga -0,83 tetapi atribut tersebut tidak dihapus hanya berdasarkan hasil korelasi. Berdasarkan Data Guide dan grain data, tidak terdapat dasar yang cukup untuk menyatakan bahwa salah satu atribut merupakan salinan langsung dari atribut lainnya. Oleh karena itu, keempat atribut tetap dipertahankan sebagai analytical features untuk tahap PCA.



Gambar 3. Heatmap korelasi hasil Stage 4. Korelasi digunakan sebagai screening redundansi, bukan penghapusan otomatis.

Kondisi	Rows	Fitur/dimensi	Keterangan
Integrated data	200.247	96 kolom	Seluruh atribut hasil integrasi tetap tersedia.
X_selected	200.247	15 kolom	3 key/identifier + 12 analytical

			numeric features.
PCA input	92.164	12 fitur	Complete-case pada 12 fitur numerik.
PCA output	92.164	8 PC + 3 key	94,51% cumulative explained variance.

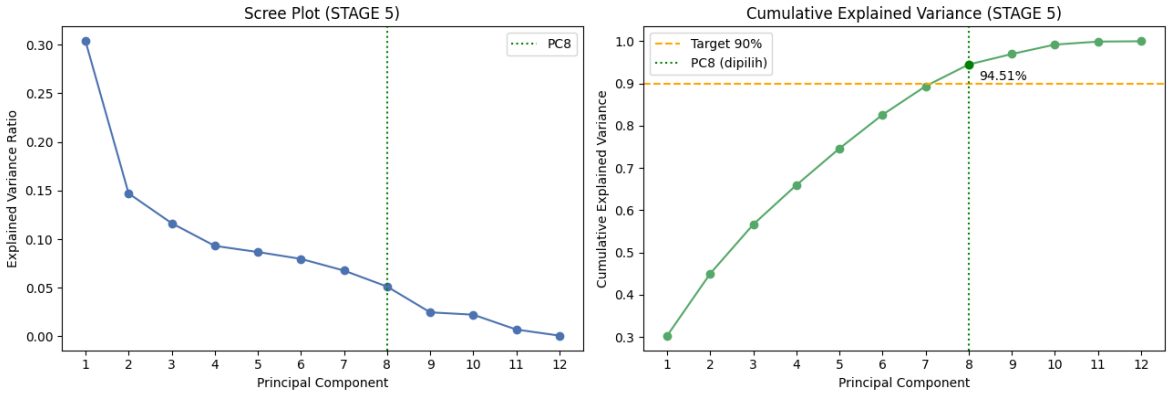
6. PCA & Dimensionality Reduction

Sebanyak 12 analytical numeric features digunakan sebagai input PCA, yaitu number_of_vehicles, number_of_casualties, speed_limit, longitude, latitude, age_of_driver, age_of_casualty, engine_capacity_cc, dan empat adjusted severity features. Identifier tidak digunakan sebagai input PCA. Sebelum PCA dilakukan, seluruh fitur distandardisasi menggunakan StandardScaler agar memiliki mean mendekati 0 dan standard deviation mendekati 1. Standardisasi diperlukan karena setiap fitur memiliki satuan dan rentang nilai yang berbeda. [4]

PCA menggunakan complete-case subset karena perhitungan membutuhkan nilai lengkap pada seluruh 12 fitur dari 200.247 baris pada X_pca_input, sebanyak 92.164 baris (46,03%) digunakan dalam PCA, sedangkan 108.083 baris (53,97%) tidak digunakan karena memiliki nilai yang tidak lengkap. Pada baris yang tidak digunakan, 72.364 merupakan vehicle tanpa casualty sehingga nilai casualty tidak tersedia pada grain hasil integrasi. Sebanyak 35.719 baris lainnya memiliki nilai yang tidak lengkap pada age_of_driver, age_of_casualty, atau engine_capacity_cc. Baris tersebut tidak dihapus dari X_selected maupun integrated_data.

PCA menghasilkan 12 komponen. Cumulative explained variance mencapai 89,39% pada PC7 dan 94,51% pada PC8. Karena target yang ditetapkan adalah minimal 90%, maka 8 komponen dipilih. Dengan demikian, dimensi numerik berkurang dari 12 menjadi 8, atau sebesar 33,33%, dengan 94,51% variance pada input PCA tetap dapat dijelaskan.

PCA menghasilkan 12 komponen. Cumulative explained variance mencapai 89,39% pada PC7 dan 94,51% pada PC8, karena target yang ditetapkan adalah minimal 90%, maka 8 komponen dipilih. Dengan demikian, dimensi numerik berkurang dari 12 menjadi 8 atau sebesar 33,33%, dengan 94,51% variance pada input PCA tetap dapat dijelaskan.



Gambar 4. Scree plot dan cumulative explained variance.
Garis target 90% tercapai pada PC8 (94,51%).

Catatan interpretasi, 94,51% menunjukkan proporsi variance statistik dari 12 fitur input yang dapat dijelaskan oleh delapan principal components. Nilai ini tidak berarti bahwa 94,51% seluruh informasi dunia nyata tetap tersedia setelah PCA.

7. Analysis & Key Insights

a. Struktur awal terdiri dari tiga tabel dengan grain yang berbeda. Setelah integrasi, data menjadi 200.247 baris dan 96 atribut, sehingga preprocessing perlu mempertimbangkan struktur dari ketiga tabel.

b. Correlation screening menunjukkan adanya informasi lokasi yang tumpang tindih. Karena longitude dan latitude sudah digunakan, location_easting_osgr dan location_northing_osgr tidak dimasukkan ke analytical feature set.

c. Empat adjusted severity features memiliki korelasi tinggi, tetapi tetap dipertahankan karena korelasi saja belum cukup untuk membuktikan bahwa atribut tersebut merupakan duplikasi.

d. PCA mengurangi 12 fitur numerik menjadi 8 principal components dengan cumulative explained variance sebesar 94,51%. Namun, PCA hanya menggunakan 46,03% dari X_selected karena membutuhkan data lengkap pada seluruh fitur. Keterbatasan ini perlu diperhatikan saat menginterpretasikan hasil PCA.

8. Before vs. After Comparison & Summary

Tahap	Kondisi data	Hasil utama
Before / raw	Collision 101.525 × 44, Vehicle 183.948 × 32, Casualty 127.883 × 23	Tiga tabel terpisah dengan grain berbeda. Kode khusus dan missing values perlu dipahami berdasarkan Data Guide.
After cleaning	Jumlah baris tabel tetap	Kode khusus ditangani berdasarkan Data Guide. Potential outlier hanya discreening dan tidak dihapus secara otomatis.
After integration	200.247 × 96	Data diintegrasikan dengan relasi 1:M. Pemeriksaan candidate key pada hasil integrasi menunjukkan tidak terdapat duplicate key.
After selection	200.247 × 15	Terdiri dari 3 key dan 12 analytical features. Atribut redundant, konstan, dan administratif tidak dimasukkan ke feature set.
After PCA	92.164 × 8 PC + key	Dimensi numerik berkurang dari 12 menjadi 8 atau 33,33%, dengan cumulative explained variance sebesar 94,51%.

Secara keseluruhan, preprocessing menggabungkan tiga tabel sumber menjadi satu integrated dataset yang terstruktur. Selanjutnya, data tersebut digunakan untuk membentuk analytical feature set yang lebih ringkas dan melakukan reduksi dimensi dengan PCA. Setiap keputusan preprocessing

didasarkan pada struktur data, Data Guide, pemeriksaan key, correlation screening, dan hasil PCA. Nilai ekstrem tidak langsung dihapus dan korelasi tinggi tidak otomatis dianggap sebagai redundancy. Pendekatan ini digunakan agar perubahan pada data tetap didukung oleh evidence.

Hasil utama tahap reduction adalah 8 principal components yang menjelaskan 94,51% cumulative variance dari 12 fitur input pada 92.164 complete-case rows. Hasil PCA hanya mencakup 46,03% dari seluruh baris data, sehingga hal ini perlu diperhatikan saat hasil PCA digunakan untuk analisis lanjutan.

References

[1] Department for Transport (DfT). Road Safety Open Data. GOV.UK. Final 2025 data; page updated 30 July 2026.

[2] Han, J., Kamber, M., & Pei, J. (2012). Data Mining: Concepts and Techniques (3rd ed.). Morgan Kaufmann.s

[3] Han, J., Kamber, M., & Pei, J. (2012). Chapter 3: Data Preprocessing Data Cleaning, Data Integration, Data Reduction.

[4] scikit-learn documentation. StandardScaler and PCA documentation, used for the implementation of standardization and principal component analysis.

Dataset source: https://www.gov.uk/government/statistical-data-sets/road-safety-open-data

Theory reference: https://www.sciencedirect.com/book/monograph/9780123814791/data-mining-concepts-and-techniques

Implementation references: https://scikit-learn.org/